

## Código Fonte

Aqui está tudo o código que utilizei para entregar a analise a Tokio School Viagens.

1. Temos o código do pre processamento.






```
colunas_categoricas = df.select_dtypes(include=["object"]).columns
valores_unicos_categoricos = {col: df[col].unique()for col in colunas_categoricas}
'Central America', 'Middle East', 'South America'], dtype=object), 'Activity Type Code': array(['Deplaned', 'Enplaned', 'Thru / Transit'], dtype=object), 'Price Category Code': array(['Low Fare', 'Other'], dtype=object), 'Boarding Area': array(['B', 'G', 'A', 'E', 'C', 'F', 'Other', 'D'], dtype=object), 'Month': array(['Deplaned', 'Febluary', 'March', 'May', 'June'], dtype=object), 'Month': array(['Deplaned', 'Febluary', 'March', 'May', 'June'], dtype=object)}
     print(valores_unicos_categoricos)
                                                                                                                                                                                                                                                                                                                                     Pytho
```

```
('Operating Airline': array('YATA Airlines', 'Air Canada', 'Air China', 'Air France',
'Air New Zealand', 'Airlina Airnays', 'Alaska Airlines',
'Ala Hispon Airnays', 'American Airlines',
'Alaerican Eagle Airlines', 'Asiana Airlines',
'British Airways', 'Cathay Pacific', 'China Airlines',
'British Airways', 'Cathay Pacific', 'China Airlines',
'Belta Air Lines', 'EVA Airways', 'Frontier Airlines',
'Hawaian Airlines', 'Horizon Air', 'Izcelandair',
'Independence Air', 'Japan Airlines', 'Kulmaya Bartines',
'Mexicana Airlines', 'Widnest Airlines', 'Mesa Airlines',
'Mexicana Airlines', 'Widnest Airlines', 'Mesa Airlines',
'Sun Country Airlines', 'Midnest Airlines', 'Skywest Airlines',
'Sun Country Airlines', 'TACA', 'Us Airways', 'United Airlines',
'United Airlines', 'Bocang Company', 'Miami Air International',
'Air Canada Jazz', 'Qantas Airways', 'Aareriflight',
'Spirit Airlines', 'Xira Airways', 'Aareriflight',
'Sirit Airlines', 'Xira Airways', 'Aareriflight',
'Sirita Airlines', 'Yerpresslet Airlines', 'Southwest Airlines',
'Virgin America', 'Aer Lingus', 'Allegiant Air', 'Jet Airways',
'Emirates', 'Mesaba Airlines', 'World Airways', 'Air Berlin',
'Republic Airlines', 'Servissir', 'Pacific Aviation',
'Suiss International', 'LMN Peru', 'Swissport USA',
'XL Airways France', 'China Eastern', 'SAS Airlines',
'Atlas Air, Inc', 'Compass Airlines', 'Stuth America'), dtype-object), 'Activity Typ.
'Central America', 'Middle East', 'South America'), dtype-object), 'Activity Typ.
                                              'Central America', 'Middle East', 'South America'], dtype=object), 'Activity Type Code': array(['Deplaned', 'Enplaned', 'Thru / Transit'], dtype=object), 'Price Category Code': array(['Low Fare', 'Other'], dty
dtype=object), 'Boarding Area': array(['8', 'G', 'A', 'E', 'C', 'F', 'Other', 'D'], dtype=object), 'Adjusted Activity Type Code': array(['Deplaned', 'Enplaned', 'Thru / Transit * 2'], dtype=object), 'Month': ar
'December', 'January', 'February', 'March', 'May', 'June'],
                                                'December', 'J
dtype=object)}
```

df\_sem\_nulos = df.dropna() (Activity Period
Operating Airline
Operating Airline
Published Airline
Published Airline
Published Airline
Activity Type Code
Price Category Code
Terminal
Boarding Area
Passenger Count
Adjusted Activity Type Code
Adjusted Activity Type Code
Adjusted Passenger Count
Year dtype: int64, (14953, 16))

```
df.to_csv("/Users/tiagosilva/Air_Traffic_Passenger_Statistics.csv", index=False)
```

2. Código para mostrar os dois pedidos detalhados.



## 3. Código PySpark

## 1 Jupyter Notebook

```
[7]: from pyspark.sql import SparkSession
 [9]: spark = SparkSession.builder \
           appName("ProjetoFinal1") \
            .config("spark.driver.bindAddress", "127.0.0.1") \
            .getOrCreate()
[10]: # Carregar o arquivo CSV em um DataFrame
       df = spark.read.option("header", "true").csv("/Users/tiagosilva/Air_Traffic_Passenger_Statistics.csv")
       # Visualizar os primeiros registros
       df.show(5)
[11]: # Contar companhias aéreas distintas
       df.select("Operating Airline").distinct().count()
 [13]: import matplotlib.pyplot as plt
 [34]: import pandas as pd
 [33]: # Calcular a média de passageiros por companhia aérea
        media1 = df.groupBy("Operating Airline").agg({"Passenger Count": "avg"})
        # Calcular a média de passageiros por companhia aérea
media = df.groupBy("Operating Airline").agg({"Passenger Count": "avg"}).toPandas()
        # Criar gráfico com os 20 principais
        media_top20 = media.head(20)
        plt.figure(figsize=(10, 6))
        plt.barh(media_top20['Operating Airline'], media_top20['avg(Passenger Count)'], color="skyblue")
         plt.xlabel("Average Passenger Count")
        plt.title("Average Number of Passengers by Airline")
        plt.tight_layout()
        # Exibir gráfico
plt.show()
  [35]: import pyspark.sql.functions as F
         # Ordenar o DataFrame pela coluna "Região GEO" e "Passageiros" de forma decrescente df_sorted = df.orderBy("GEO Region", F.desc("Passenger Count"))
         # Eliminar duplicados com base na coluna "Região GEO", mantendo o primeiro (que terá o maior número de passageiros)
         sem_duplicados = df_sorted.dropDuplicates(["GEO Region"])
         # Mostrar o DataFrame final
         sem_duplicados.show()
 [37]: # Salvar o DataFrame em CSV
        medial.write.option("header", "true").csv("/Users/tiagosilva/media")
sem_duplicados.write.option("header", "true").csv("/Users/tiagosilva/sem_duplicados")
```

## 2 Jupyter Notebook

```
[27]: # Vamos calcular as médias e desvios padrão por diferentes categorias
           # Número de passageiros por ano
           group_by_year = df.groupBy('Year').agg({'Passenger Count': 'avg', 'Passenger Count': 'stddev'}).toPandas()
           # Número de passageiros por mês
           group_by_month = df.groupBy('Month').agg({'Passenger Count': 'avg', 'Passenger Count': 'stddev'}).toPandas()
           # Número de passageiros por companhia aérea
           group_by_airline = df.groupBy('Operating Airline').agg({'Passenger Count': 'avg', 'Passenger Count': 'stddev'}).toPandas()
           # Número de passageiros por tipo de atividade
           group_by_activity = df.groupBy('Activity Type Code').agg({'Passenger Count': 'avg', 'Passenger Count': 'stddev'}).toPandas()
           # Número de passageiros por terminal
           group_by_terminal = df.groupBy('Terminal').agg({'Passenger Count': 'avg', 'Passenger Count': 'stddev'}).toPandas()
           # Exibir as tabelas
print("Passenger Count per Year")
           display(group_by_year)
           print("\nPassenger Count per Month")
           display(group_by_month)
           print("\nPassenger Count per Airline")
           display(group_by_airline)
           print("\nPassenger Count per Activity Type")
           display(group_by_activity)
           print("\nPassenger Count per Terminal")
           display(group_by_terminal)
  [5]: import pandas as pd
 [14]: # Para usar Pandas e gerar gráficos, convertemos o DataFrame PySpark para Pandas
            df_pandas = df.toPandas()
            import matplotlib.pyplot as plt
             # Função para gerar gráficos de barras e também retornar os dados numericamente
           def plot_bar_chart_with_data(dataframe, x_col, y_col, title, xlabel, ylabel):
    plt.figure(figsize=(10, 6))
                   plt.bar(dataframe[x_col], dataframe[y_col], color='skyblue')
                   plt.title(title)
                   plt.xlabel(xlabel)
                   plt.ylabel(ylabel)
                   plt.xticks(rotation=45)
                   plt.tight_layout()
                   plt.show()
                   return dataframe[[x_col, y_col]]
           # Converter as colunas numéricas corretamente (garantir que a conversão de texto para número está correta)
df_pandas['Passenger Count'] = pd.to_numeric(df_pandas['Passenger Count'], errors='coerce')
df_pandas['Year'] = pd.to_numeric(df_pandas['Year'], errors='coerce')
            # 1. Número de passageiros por ano
           group_by_year = df_pandas.groupby('Year')['Passenger Count'].agg(['mean']).reset_index()
            numerical_data_year = plot_bar_chart_with_data(group_by_year, 'Year', 'mean', 'Média de Passageiros por Ano', 'Ano', 'Média de Passageiros')
           # 2. Numero de passageiros por mies
group_by_month = df_pandas.groupby('Month')['Passenger Count'].agg(['mean']).reset_index()
numerical_data_month = plot_bar_chart_with_data(group_by_month, 'Month', 'mean', 'Média de Passageiros por Mês', 'Mês', 'Média de Passageiros'
            # 3. Número de passageiros por companhia aérea (Top 10)
            group_by_airline = df_pandas.groupby('Operating Airline')['Passenger Count'].agg(['mean']).reset_index()
             top_10_airlines = group_by_airline.sort_values(by='mean', ascending=False).head(10)
            numerical_data_airlines = plot_bar_chart_with_data(top_10_airlines, 'Operating Airline', 'mean', 'Top 10 Companhias Aéreas por Média de Passag
           # 4. Número de passageiros por tipo de atividade
group_by_activity = df_pandas.groupby('Activity Type Code')['Passenger Count'].agg(['mean']).reset_index()
            numerical_data_activity = plot_bar_chart_with_data(group_by_activity, 'Activity Type Code', 'mean', 'Média de Passageiros por Tipo de Atividad
            # 5. Número de passageiros por terminal
            group_by_terminal = df_pandas.groupby('Terminal')['Passenger Count'].agg(['mean']).reset_index()
            numerical_data_terminal = plot_bar_chart_with_data(group_by_terminal, 'Terminal', 'mean', 'Média de Passageiros por Terminal', 'Terminal', 'Média de Passageiros por Terminal', 'Terminal', 'Média de Passageiros por Terminal', 'Média d
```

```
# Após codificar, posso calcular a matriz de correlação apenas para colunas numéricas
# Selecionar colunas numéricas para a correlação
numeric_cols = ['Passenger Count', 'Adjusted Passenger Count', 'Year'] + [col + "_Indexed" for col in categorical_cols]

# Criar uma nova tabela apenas com as colunas numéricas
df_numeric = df.select(numeric_cols)

# Converter para Pandas para calcular a correlação (ou usar um método alternativo no PySpark)
df_numeric_pandas = df_numeric.toPandas()

# Calcular a matriz de correlação
correlation_matrix = df_numeric_pandas.corr()

# Exibir a matriz de correlação
print(correlation_matrix)
```